

## Cursul 9

# Simularea distribuțiilor de probabilitate

### 9.1 Simularea distribuțiilor de probabilitate discrete

A simula o variabilă aleatoare discretă  $X$  presupune a genera independent, conform unui algoritm, un șir de numere  $y_1, y_2, \dots, y_N$  care să aibă particularitățile unor valori de observație asupra variabilei. Mai precis, dacă variabila aleatoare  $X$  are distribuția de probabilitate

$$X = \begin{pmatrix} x_1 & x_2 & \dots & x_n \\ p_1 & p_2 & \dots & p_n \end{pmatrix},$$

atunci distribuția experimentală a datelor generate trebuie să fie foarte apropiată de distribuția teoretică a variabilei  $X$ . Și anume, dacă notăm cu  $nr_k$  numărul valorilor generate egale cu  $x_k$ ,  $k = \overline{1, n}$ , atunci raportul  $nr_k/N$  trebuie să fie apropiat de  $p_k$ .

În continuare prezentăm metode de simulare a variabilelor aleatoare ce au diverse distribuții de probabilitate. Pentru fiecare distribuție de probabilitate dăm pseudocodul pentru o funcție ce returnează o singură valoare de observație simulată. O astfel de valoare se obține printr-o transformare aplicată unei valori  $u$  presupusă a fi returnată de un generator de numere pseudo-aleatoare uniform distribuite pe  $[0, 1)$ .

**Apelul acestui generator îl simbolizăm în continuare prin `urand()`.** Acesta este un nume generic pentru simulatorul unei variabile aleatoare  $U \sim Unif[0, 1)$ .

Reamintim:

Dacă  $U \sim Unif[0, 1)$ , atunci pentru orice interval  $I \subset [0, 1)$ , probabilitatea ca  $U$  să ia valori în acest interval este egală cu lungimea intervalului.

Dacă  $A$  este un eveniment de probabilitate  $P(A) = 0.65$  și  $B = \overline{A}$ , atunci putem simula producerea unuia din cele două evenimente astfel:

- apelăm generatorul `urand()`:

$$u = \text{urand()};$$

- Dacă  $u < 0.65$ , spunem că s-a produs evenimentul ( $U < 0.65$ ), care are probabilitatea  $P(U < 0.65) = P(U \in [0, 0.65)) = 0.65$ , adică lungimea intervalului. Cum și  $A$  are aceeași probabilitate, putem considera că s-a produs evenimentul  $A$ .

• Dacă  $u \in [0.65, 1)$ , atunci s-a produs evenimentul ( $U \in [0.65, 1)$ ) a cărui probabilitate este  $P(U \in [0.65, 1)) = 1 - 0.65 = 0.35$ . Deci, în acest caz, putem considera că s-a produs evenimentul  $B$ .

Această modalitate de a genera evenimente se folosește foarte mult în algoritmi randomizați [http://en.wikipedia.org/wiki/Randomized\\_algorithm](http://en.wikipedia.org/wiki/Randomized_algorithm).

### 9.1.1 Simularea variabilei Bernoulli

Reamintim că o variabilă aleatoare Bernoulli are distribuția

$$X = \begin{pmatrix} 1 & 0 \\ p & 1 - p \end{pmatrix}, p \in (0, 1).$$

Ea se simulează când avem de făcut o alegere din două alternative, codificate cu 1, respectiv 0. Pentru început, se generează  $u \in [0, 1)$  apelând `u = urand()`;



Dacă  $u < p$ , înseamnă că s-a produs evenimentul ( $U < p$ ), a cărui probabilitate este

$$P(U < p) = P(0 \leq U < p) = p - 0 = p.$$

Dar cum și evenimentul ( $X = 1$ ) are probabilitatea  $p$ , putem presupune că s-a produs acesta, deci facem alegerea codificată cu 1. Dacă însă  $u \geq p$ , atunci facem alegerea codificată cu 0.

Astfel, algoritmul de simulare a unei variabile aleatoare Bernoulli este:

```

1: function Bernoulli(p)
2:   u=urand();
3:   if(u < p) return 1;
4:   else return 0;
5: end function

```

Acest algoritm se poate aplica la generarea unui șir de biți aleatori, la căutarea aleatoare într-un arbore binar etc.

### 9.1.2 Simularea distribuției uniforme discrete

**Propoziția 9.1.1** *Dacă  $U \sim Unif[0, 1)$  este o variabilă aleatoare uniform distribuită pe intervalul  $[0, 1)$  și  $n \in \mathbb{N}^*$ , atunci variabila aleatoare  $X = [nU]$  ( $[x]$  notează partea întreagă a lui  $x$ ) este o variabilă aleatoare discretă ce are distribuția uniformă pe mulțimea  $\{0, 1, \dots, n-1\}$ , adică*

$$X = \begin{pmatrix} 0 & 1 & \dots & n-1 \\ \frac{1}{n} & \frac{1}{n} & \dots & \frac{1}{n} \end{pmatrix}.$$

**Demonstrație:** Deoarece variabila aleatoare  $U$  ia valori în  $[0, 1)$ , variabila  $nU$  ia valori în  $[0, n)$  și  $[nU] \in \{0, 1, \dots, n-1\}$ . Deci, variabila  $X = [nU]$  are ca mulțime de valori  $\{0, 1, \dots, n-1\}$ .

Să arătăm că probabilitatea ca  $X$  să ia valoarea  $k$ ,  $k = \overline{0, n-1}$ , este  $P(X = k) = \frac{1}{n}$ :

$$\begin{aligned} P(X = k) &= P([nU] = k) = P(k \leq nU < k+1) \\ &= P\left(\frac{k}{n} \leq U < \frac{k+1}{n}\right) \\ &= \frac{k+1}{n} - \frac{k}{n} = \frac{1}{n}. \end{aligned}$$

Am demonstrat astfel că  $X$  este o variabilă aleatoare uniform distribuită pe mulțimea  $\{0, 1, \dots, n-1\}$ .  $\square$

Exploatând această relație dintre variabila aleatoare discretă  $X$  și variabila aleatoare  $U$ , avem următorul algoritm ce returnează o valoare de observație asupra variabilei  $X$  pe mulțimea  $\{0, 1, \dots, n-1\}$ :

```
1: function SimDiscretU(n)
2:   u=rand();
3:   k=int(n*u);
4:   return k;
5: end function
```

Înlocuind `return k;` cu `return  $x_k$ ;` se returnează o valoare de observație asupra unei variabile aleatoare discrete uniform distribuită pe o mulțime  $\{x_0, x_1, \dots, x_{n-1}\}$ , adică asupra variabilei aleatoare:

$$X = \begin{pmatrix} x_0 & x_1 & \dots & x_{n-1} \\ \frac{1}{n} & \frac{1}{n} & \dots & \frac{1}{n} \end{pmatrix}.$$

Simularea acestei variabile aleatoare este echivalentă cu simularea experimentului de extragere la întâmplare a unui element (obiect) din lista  $x_0, x_1, \dots, x_{n-1}$  și returnarea lui în "recipientul" din care a fost scos. La întâmplare înseamnă că fiecare element are aceeași șansă de a fi extras, adică probabilitatea  $1/n$ .

**Algoritmul ce extrage un număr la întâmplare din mulțimea de numere întregi  $M = \{m, m+1, \dots, n\}$ ,  $m < n$ .**

Mulțimea  $M$  conține  $N = n - m + 1$  elemente. Un număr selectat la întâmplare din această mulțime este o valoare de observație asupra variabilei aleatoare:

$$X = \begin{pmatrix} m & m+1 & \dots & n \\ 1 & 1 & \dots & 1 \\ \frac{m}{n-m+1} & \frac{m+1}{n-m+1} & \dots & \frac{n}{n-m+1} \end{pmatrix}.$$

```

1: function randint(m,n)
2:   u=rand();
3:   k=int((n-m+1)*u));//k in {0,1,2,...,n-m}
4:   return k+m;
5: end function

```

### 9.1.3 Simularea variabilelor aleatoare discrete având o distribuție generală neuniformă


Fie  $X$  o variabilă aleatoare discretă ce are distribuția de probabilitate

$$X = \begin{pmatrix} x_0 & x_1 & \cdots & x_{n-1} \\ p_0 & p_1 & \cdots & p_{n-1} \end{pmatrix}, \quad \sum_{k=0}^{n-1} p_k = 1,$$

valorile sale sunt ordonate crescător, adică  $x_0 < x_1 < \cdots < x_{n-1}$ .

Ținând seama că  $\sum_{k=0}^{n-1} p_k = 1$ , divizăm intervalul  $[0, 1)$  prin punctele

$$0, F_0 = p_0, F_1 = p_0 + p_1, \dots, F_k = p_0 + p_1 + \cdots + p_k, \dots, F_{n-1} = 1.$$



Probabilitatea ca un număr  $u$ , valoare de observație asupra variabilei  $U \sim Unif[0, 1)$ , să cadă într-un interval de forma  $I_k = [F_{k-1}, F_k)$ ,  $k = 1, 2, \dots, n-1$ , este

$$P(U \in [F_{k-1}, F_k)) = \underbrace{F_k - F_{k-1}}_{\text{lungime interval}} = p_k = P(X = x_k),$$

respectiv  $P(U \in I_0 = [0, F_0)) = F_0 - 0 = p_0$ .

Rezultă că evenimentul  $(X = x_k)$  se produce cu aceeași probabilitate ca și evenimentul ca  $U$  să ia valori în intervalul  $I_k$ . Deci, generând  $u$  în intervalul  $I_k$  este echivalent cu producerea evenimentului  $(X = x_k)$  și în acest caz generatorul lui  $X$  returnează elementul  $x_k$ ,  $k = 0, 1, \dots, n-1$ .

Algoritmul de generare a unui număr pseudo-aleator din legea de probabilitate a variabilei discrete  $X$  ce ia valorile  $x_k$  cu probabilitățile  $p_k$ ,  $k = 0, 1, \dots, n-1$ , este:

```

1: function SimDiscret(x,p,n)//x, p sunt tablouri de n elemente
2:   k = 0;
3:   F = p_0;
4:   u=rand();
5:   while (u >= F){
6:     k = k + 1;

```

```

7:    $F = F + p_k$ ;
8:   }
9:   return  $x_k$ ;
10: end function

```

Metoda prezentată mai sus, de căutare secvențială a intervalului în care cade numărul  $u$ , este recomandată doar pentru simularea variabilelor aleatoare care au un număr redus de valori  $x_0, x_1, \dots, x_{n-1}$ .

Pentru variabilele aleatoare discrete cu număr mare de valori se recomandă calcularea prealabilă a sumelor  $F_k = p_0 + p_1 + \dots + p_k$ ,  $k = \overline{0, n-1}$ , și căutarea binară a intervalului  $I_k$  în care cade numărul  $u \in [0, 1)$ , returnat de `urand()`.

### 9.1.4 Simularea distribuției geometrice

Fie  $X$  o variabilă aleatoare ce are distribuția geometrică de parametru  $p \in (0, 1)$ .  $X$  dă numărul de încercări într-un experiment Bernoulli până la primul succes înregistrat, inclusiv. Distribuția de probabilitate este ilustrată în tabloul:

$$X = \binom{k}{p(1-p)^{k-1}}, \quad k \in \mathbb{N}^*.$$

Metoda directă de simulare, exploatând faptul că o variabilă geometrică este asociată unui experiment Bernoulli, este următoarea:

```

1: function Geom1( $p$ )
2:    $k=0$ ; //  $k$  contorul pentru încercările Bernoulli
3:   do {
4:      $u=urand()$ ;
5:      $k=k+1$ ;
6:   } while ( $u > p$ );
7:   return  $k$ ;
8: end function

```

Se execută blocul de instrucțiuni din bucla **do-while** atâta timp cât încercările sunt un eșec. La primul succes returnează numărul încercării respective. Dacă probabilitatea succesului  $p$  este mică, atunci numărul mediu de încercări până la primul succes este mare pentru că  $M(X) = 1/p$  și în acest caz algoritmul **Geom1** este ineficient.

O modalitate mai rapidă de simulare a variabilei aleatoare  $X$  rezultă din următoarea propoziție:

**Propoziția 9.1.2** Dacă  $p \in (0, 1)$  și  $U \sim Unif[0, 1)$ , atunci variabila aleatoare

$$X = \left\lceil \frac{\ln(1-U)}{\ln(1-p)} \right\rceil + 1 \tag{9.1}$$

are distribuția geometrică de parametru  $p$ .

**Demonstrație:** Notăm cu  $Y$  variabila aleatoare

$$Y = \left\lfloor \frac{\ln(1-U)}{\ln(1-p)} \right\rfloor.$$

Fie  $u$  o valoare de observație asupra variabilei aleatoare  $U$ , adică  $u \in [0, 1)$  este generat de `urand()`. Dacă  $u = 0$ , atunci  $Y = 0$ . În caz contrar,  $Y$  este un întreg pozitiv. Deci,  $Y$  este o variabilă aleatoare discretă ce ia valori în  $\mathbb{N}$ . În continuare arătăm că probabilitatea evenimentului  $(Y = k)$  coincide cu probabilitatea unui eveniment  $E$ , asociat variabilei aleatoare  $U$ , pe care în plus îl putem și simula. Are loc

$$P(Y = k) = P\left(\left\lfloor \frac{\ln(1-U)}{\ln(1-p)} \right\rfloor = k\right).$$

Dar cum partea întreagă  $[x] = k$  implică  $k \leq x < k+1$ , avem

$$P(Y = k) = P\left(k \leq \frac{\ln(1-U)}{\ln(1-p)} < k+1\right).$$

Deoarece  $\ln(1-p) < 0$ , rezultă

$$\begin{aligned} P(Y = k) &= P((k+1)\ln(1-p) < \ln(1-U) \leq k\ln(1-p)) \\ &= P(\ln(1-p)^{k+1} < \ln(1-U) \leq \ln(1-p)^k) \\ &= P((1-p)^{k+1} < 1-U \leq (1-p)^k) \\ &= P(-(1-p)^k \leq U-1 < -(1-p)^{k+1}) \\ &= P(1-(1-p)^k \leq U < 1-(1-p)^{k+1}). \end{aligned}$$

Cum variabila  $U$  este uniform distribuit pe  $[0, 1)$  obținem

$$P(1-(1-p)^k \leq U < 1-(1-p)^{k+1}) = 1-(1-p)^{k+1} - (1-(1-p)^k) = (1-p)^k p.$$

Pe de altă parte,  $X = Y + 1$ , deci

$$P(X = k) = P(Y + 1 = k) = P(Y = k-1) = (1-p)^{k-1} p,$$

ceea ce implică faptul că variabila aleatoare  $X$  are distribuția geometrică de parametru  $p$ .  $\square$

Ținând seama că pentru variabila aleatoare  $X \sim \text{Geom}(p)$ , evenimentul  $(X = k)$  are aceeași probabilitate ca evenimentul  $\left(\left\lfloor \frac{\ln(1-U)}{\ln(1-p)} \right\rfloor + 1 = k\right)$ , rezultă că se poate genera o valoare de observație  $x$  asupra lui  $X$  astfel:

```

1: function Geom2( $p$ )
2:   u=urand();
3:   return int(log(1-u)/log(1-p)) + 1;
4: end function
```

## 9.2 Simularea distribuțiilor de probabilitate continue

### 9.2.1 Simularea distribuției uniforme pe intervalul $[a, b]$

Fie  $a, b \in \mathbb{R}$  cu  $a < b$ . Simularea unei variabile aleatoare uniforme pe intervalul  $[a, b]$  se bazează pe următorul rezultat:

**Propoziția 9.2.1** *Dacă  $U \sim \text{Unif}[0, 1]$ , atunci variabila aleatoare  $X = a + (b - a)U$  este o variabilă aleatoare ce are distribuția uniformă pe  $[a, b]$ .*

**Demonstrație:** Vom arăta că funcția de repartiție  $F_X$  a variabilei  $X$  concide cu funcția de repartiție a distribuției uniforme pe  $[a, b]$ . Pentru  $x \in [a, b]$ , avem  $\frac{x - a}{b - a} \in [0, 1]$ . Reamintim că funcția de repartiție a lui  $U$  este  $F_U(u) = u$ ,  $\forall u \in [0, 1]$ . Astfel, avem

$$\begin{aligned} F_X(x) = P(X \leq x) &= P(a + (b - a)U \leq x) = P\left(U \leq \frac{x - a}{b - a}\right) \\ &= F_U\left(\frac{x - a}{b - a}\right) = \frac{x - a}{b - a}. \end{aligned}$$

În mod analog se obțin și celelalte două cazuri:  $x < a$ , respectiv  $x \geq b$ . □

Plecând de la rezultatul de mai sus, dăm următorul algoritm de simulare a unei valori corespunzătoare unei variabile aleatoare uniform distribuite pe intervalul  $[a, b]$ :

```

1: function Unif( $a, b$ )
2:   u=urand();
3:   return  $a + (b - a) * u$ ;
4: end function
```

### 9.2.2 Simularea unei distribuții de probabilitate prin metoda inversării

Metoda inversării de simulare a unei variabile aleatoare continue se aplică pentru acele variabile ce au funcția de repartiție inversabilă pe un anumit interval. Reamintim că funcția de repartiție a unei variabile aleatoare continue  $X$ , care admite densitatea de probabilitate  $f$ , este funcția  $F_X : \mathbb{R} \rightarrow [0, 1]$  definită prin

$$F_X(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt. \quad (9.2)$$

Funcția de repartiție  $F_X$  a unei variabile aleatoare continue  $X$  verifică următoarele proprietăți:

- este continuă pe  $\mathbb{R}$ ;

- este crescătoare, adică dacă  $x_1 < x_2$ , atunci  $F_X(x_1) \leq F_X(x_2)$ ;
- $\lim_{x \rightarrow -\infty} F_X(x) = 0$ , iar  $\lim_{x \rightarrow \infty} F_X(x) = 1$ .

De interes deosebit pentru simulare este funcția de repartiție  $F_U$  a unei variabile aleatoare  $U \sim Unif[0, 1)$ ,

$$F_U(x) = \begin{cases} 0, & x < 0, \\ x, & x \in [0, 1), \\ 1, & x \geq 1. \end{cases}$$

Șirurile de numere pseudo-aleatoare uniform distribuite pe intervalul  $[0, 1)$  constituie baza oricărei simulări a unui fenomen sau proces aleator. Prin transformări inversabile  $h : D \subset [0, 1) \rightarrow \Delta \subset \mathbb{R}$ , adecvat alese, un șir  $(u_n)$  de numere uniform distribuite pe  $[0, 1)$  poate fi transformat într-un șir  $x_n = h(u_n)$  ale cărui elemente sunt valori de observație asupra unei variabile aleatoare  $X = h(U)$  cu  $U \sim Unif[0, 1)$ .

Cea mai simplă metodă de transformare a șirului  $(u_n)$  într-un șir  $(x_n)$  ca mai sus este metoda inversării. Aceasta se aplică pentru a genera numere pseudo-aleatoare ca valori de observație asupra unei variabile aleatoare  $X$ , ce are funcția de repartiție inversabilă pe un anumit interval  $I$ . Evident că dacă  $F_X$  este strict crescătoare pe  $I$ , atunci ea este inversabilă pe  $I$ . Interpretând  $u$  ca valoare de observație asupra unei variabile aleatoare  $U \sim Unif[0, 1)$ ,  $x = h(u)$  este valoare de observație asupra variabilei  $F_X^{-1}(U)$ .

**Propoziția 9.2.2** *Fie  $U$  o variabilă aleatoare uniform distribuită pe  $[0, 1)$  și  $F_X$  funcția de repartiție a variabilei aleatoare continue  $X$ . Dacă  $F_X$  este strict crescătoare (injectivă) pe un interval  $I$  din  $\mathbb{R}$  pe care variabila aleatoare  $X$  ia valori cu probabilitatea 1, adică  $P(X \in I) = 1$ , atunci variabila aleatoare*

$$Y = F_X^{-1}(U)$$

*are aceeași funcție de repartiție ca și variabila  $X$ , adică  $Y$  și  $X$  sunt identic distribuite.*

**Demonstrație:** Cum  $U \sim Unif[0, 1)$ , funcția sa de repartiție  $F_U$  este funcția identică pe  $[0, 1]$ , adică  $F_U(x) = x$ ,  $\forall x \in [0, 1]$ . Să determinăm funcția de repartiție  $F_Y$  a variabilei  $Y = F_X^{-1}(U)$ :

$$F_Y(x) = P(Y \leq x) = P(F_X^{-1}(U) \leq x) = P(U \leq F_X(x)) = F_U(F_X(x)) = F_X(x).$$

Prin urmare  $F_Y(x) = F_X(x)$ , pentru orice  $x \in I$ . Dar cum  $P(X \in I) = 1$ , rezultă că funcția de repartiție a variabilei aleatoare  $Y = F_X^{-1}(U)$  coincide din punct de vedere probabilist cu  $F_X$ .  $\square$

Bazat pe acest rezultat, avem următorul algoritm de simulare a unei variabile aleatoare  $X$  ce are funcția de repartiție  $F_X$  inversabilă:




```

1: function MetodaInversarii()
2:   u=rand();
3:   x = FX-1(u);
4:   return x;
5: end function

```

**Simularea distribuției exponențiale de parametru  $\theta > 0$ :** Funcția de repartiție a unei variabile aleatoare  $X \sim \text{Exp}(\theta)$  (Fig. 9.1) este:

$$F(x) = \begin{cases} 0, & \text{dacă } x < 0, \\ 1 - e^{-x/\theta}, & \text{dacă } x \geq 0. \end{cases} \quad (9.3)$$



**Fig.9.1:** Funcția de repartiție a unei variabile aleatoare  $X \sim \text{Exp}(\theta)$ .

Observăm că funcția  $F$  este strict crescătoare pe intervalul  $[0, \infty)$ , deci pentru orice  $u \in [0, 1)$ ,  $F^{-1}(u) \in [0, \infty)$ . Cum o variabilă aleatoare exponențial distribuită ia valori nenegative cu probabilitatea 1,

$$P(X \geq 0) = 1 - P(X < 0) = 1 - F(0) = 1 - 0 = 1,$$

rezultă că putem aplica metoda inversării pentru simularea lui  $X$ .

Din  $1 - e^{-x/\theta} = u$ , rezultă că

$$x = F^{-1}(u) = -\theta \ln(1 - u).$$

Astfel, putem simula variabila aleatoare  $X$  în modul următor:

```

1: function SimulExp(theta)
2:   u=rand();
3:   x = -theta * log(1 - u);
4:   return x;
5: end function

```